

论文图表布局设计与实验实施方案（第一版）

文潇墨，2025 年 12 月 4 日

一、研究背景与核心动机

考虑以此作为核心卖点并做扩充后，将其写进论文中的对背景的“一句话介绍”：针对现有 Cross-View Geo-Localization (CVGL) 模型在理想数据集（如 University-1652）上表现优异，但在真实复杂环境（恶劣天气、传感器噪声、飞行抖动）下性能急剧下降的问题，本项目提出一种**基于旋转位置编码 (RoPE) 与对比一致性学习 (Contrastive Consistency Learning)** 的鲁棒性框架。

关于数据集的技术方案：我交给我下面的师弟去写了，他找了一些以“做增强版的数据集”为核心卖点的文章正在看，然后我让他以书面形式写出来大致的做数据集的思路、计划、以及这么做的可行性（找一些顶会顶刊发布的文章，表明这么做不是空穴来风），大约一两天写出来第一版。

当然，为了适应 ICIP 4页短文的篇幅限制，也考虑到可能会被审稿人攻击到的“工作量”、“不够 Novel”、“不够SOTA”这些点（烦请老师您也看看有没有其他容易被攻击的点），个人觉得卖点策略应该从“追求极致精度”转向“追求更鲁棒”（在主任务上确实刷不过25年最新的90%+的SOTA，但是差距可以追到 1%-2%，把卖点转向这个人造受损数据集University-C上的表现）。以下是论文排版与实验设计的详细方案的初稿，请您和邓博士过目。

二、论文图表布局设计

针对 ICIP 紧凑的篇幅，我觉得可以用“**2图 + 2表**”的配置，下面是具体说明：

1. Figure 1: 整体架构图 (The Framework)

- 计划位置：**第 2 页顶部
- 设计内容：**
 - 展示双流 Siamese 网络结构：
 - Stream A (Query):** 输入原始 UAV 图像 (x)。
 - Stream B (Augmented):** 输入随机强增强后的 UAV 图像 (x_{aug})，模拟环境干扰。
 - Encoder部分的核心组件：**
 - RoPE 模块：**明确标注其嵌入在 Encoder 中，用于处理几何旋转。
 - Projection Head：**仅在训练阶段使用的映射头。
 - 损失函数路径：**
 - Stream A 与 Satellite 图像计算 **Retrieval Loss** (Task Loss)。

- Stream A 与 Stream B 的特征通过虚线连接，计算 **InfoNCE Loss** (Consistency Loss)。

- 图注草案：

Fig. 1. Overview of the proposed Robustness-Oriented Framework. We introduce a weight-shared dual-branch architecture equipped with **Rotational Position Embeddings** to handle geometric misalignment. A **Contrastive Consistency Loss** is employed to minimize the distributional divergence between clean and corrupted views, enforcing the model to learn environment-invariant representations.

有个问题：文中类似这样的脚注里要不要加粗表示一些“关键模块”，比如这里的RoPE、Contrastive Consistency Loss 之类的。

2. Table 1: 综合性能对比 (Main Quantitative Results)

- 计划位置：第 3 页顶部。
- 设计目的：展示核心竞争力——“在恶劣环境下，我们比 SOTA 更稳定”。
- 表格结构：
 - 列设置：
 - Method:** 包括 Baseline (ResNet50/LPN), Competitors (FSRA/MBF/CAMP), Ours。
 - Standard Test Set (Clean):** 原始 University-1652 的 R@1 和 AP。
 - University-1652-C (Robustness Benchmark):** 我们构建的受损数据集上的平均 R@1 和 AP。
(核心得分点)
 - Drop Rate (↓):** 性能下降幅度。(important)

$$\text{Drop Rate} = \frac{\text{R@1}_{\text{clean}} - \text{R@1}_{\text{corrupted}}}{\text{R@1}_{\text{clean}}} \times 100\%$$

- 理想的效果：我们的 Clean R@1 可能略低于最新 SOTA（如 -2 左右%），但在 University-1652-C 上显著高于 SOTA（也就是 Drop Rate 显著更低。）

Table 1. Quantitative comparison with state-of-the-art methods on the standard University-1652 dataset and our proposed **University-1652-C** benchmark. "Drop Rate" measures the relative performance degradation (↓) from clean to corrupted settings. While maintaining competitive performance on the standard set, our method significantly outperforms competitors in robust evaluation, achieving the lowest performance drop.

3. Table 2: 消融实验 (Ablation Study)

- **计划位置：** 第 3 页底部
- **设计目的：** 证明各组件 (RoPE, InfoNCE) 的独立有效性及互补性。
- **表格行设置：**
 1. Baseline (无 RoPE, 无 InfoNCE)
 2. Baseline + RoPE (验证几何对齐的贡献)
 3. Baseline + InfoNCE (验证语义一致性的贡献)
 4. Ours (Full Model)
- **预期结论：** RoPE 提升了旋转场景下的匹配，InfoNCE 提升了抗噪能力，两者结合效果最佳。

Table 2. Ablation study on the impact of key components. We incrementally integrate **Rotational Position Embeddings (RoPE)** and **Contrastive Consistency Loss (InfoNCE)** into the baseline. The results demonstrate that both modules are essential and complementary, effectively addressing geometric misalignment and semantic noise respectively.

4. Figure 2: 鲁棒性分析可视化 (Robustness Analysis)

布局： 分为左右或上下两部分，综合展示定量趋势与定性效果。（版面允许也许可以拆成两个图）

Sub-figure 2a: Hyper-parameter Sensitivity (参数敏感性):

- **形式：** 一个小的折线图。
- **内容：** X 轴为 Loss 权重 λ ，Y 轴为 R@1。
- **目的：** 证明模型在 $\lambda \in [0.3, 0.7]$ 区间内性能稳定，并非过度调参的结果。（相当与给 λ 做了一个消融实验）

Sub-figure 2b: Qualitative Visualization (检索可视化，理想规划，实际也不知是否可行):

- **Part 1 (Synthetic):** 展示 University-1652-C 中的雨/雾样本，对比 Baseline（错）和 Ours（对），我看顶刊顶会上的文章多使用 Attention 的热力图来直观展现自己的模型可以关注到别人关注不到的地方，但是我暂时不知道这个怎么操作。
- **Part 2 (Real-world):** 展示实地拍摄（有机会就自己拍，没机会就找别人拍的）的极端样本（如傍晚弱光、飞行抖动图），模型依然能成功匹配到 Google Earth 卫星图。

关于上面的定性检索结果 (Qualitative Visualization)

- **位置：** 第 4 页顶部。
- **设计内容：** Top-1 检索结果对比可视化。
 - 选取 3 个极端案例： **Heavy Rain (大雨)**, **Motion Blur (运动模糊)**, **Low Light (低光)**。
 - 展示三行图片：
 1. **Query:** 受损的无人机图像。
 2. **Baseline Result:** 检索错误的卫星图（用红框标记）。
 3. **Ours Result:** 检索正确的卫星图（用绿框标记）。
- **设计目的：** 提供直观的视觉证据，证明 Baseline（这个我觉得挑个ResNet都行，反正是用来踩的）被环境噪声误导，而我们的模型关注到了建筑结构。

Fig. 2. Comprehensive robustness analysis. **(a) Hyper-parameter sensitivity:** The R@1 performance remains stable across a wide range of $\lambda \in [0.3, 0.7]$, indicating the method's reliability without over-tuning. **(b) Qualitative visualization:** Top-1 retrieval results under synthetic corruptions (University-1652-C) and real-world tests (Campus Data). Green and red borders indicate correct and incorrect matches, respectively. Our model successfully retrieves targets by focusing on invariant structural cues, whereas the baseline is misled by environmental interference (e.g., heavy rain streaks or motion blur).